

Auteurs:

Robrecht Dockx , Hans Van Calster , Third Author 

Reviewers:

First Reviewer 

Het INBO is het onafhankelijk onderzoeksinstituut van de Vlaamse overheid dat via toegepast wetenschappelijk onderzoek, data- en kennisontsluiting het biodiversiteitsbeleid en -beheer onderbouwt en evalueert.

Vestiging:

INBO Brussel, Herman Teirlinckgebouw, Havenlaan 88 bus 73, 1000 Brussel, België
[vlaanderen.be/inbo](https://www.vlaanderen.be/inbo)

e-mail:

robrecht.dockx@inbo.be

Wijze van citeren:

Dockx, R. et al. (9999). Analysis kartering. Rapporten van het Instituut voor Natuur- en Bosonderzoek 9999 (3.14). Instituut voor Natuur- en Bosonderzoek, Brussel. DOI:
[10.5281/zenodo.842223](https://doi.org/10.5281/zenodo.842223)

optional depot number

Rapporten van het Instituut voor Natuur- en Bosonderzoek 9999 (3.14)

ISSN: 1782-9054

Verantwoordelijke uitgever:

Hilde Eggermont

Foto cover:

Detail of a leaf. Photo by [Skyler Ewing](#) via [Pexels](#)

Dit onderzoek werd uitgevoerd in opdracht van:

INBO Brussel
VAC Brussel - Herman Teirlinck
Havenlaan 88 bus 73
1000 Brussel
<https://www.vlaanderen.be/inbo/en-gb>

Dit onderzoek werd uitgevoerd in samenwerking met:

INBO Brussel
VAC Brussel - Herman Teirlinck
Havenlaan 88 bus 73
1000 Brussel
<https://www.vlaanderen.be/inbo/en-gb>



Dit werk valt onder een [Creative Commons Naamsvermelding 4.0 Internationaal-licentie](#).

HISTMAP_VALIDATION_QUARTO

Robrecht Dockx, Hans Van Calster, Third Author
10.5281/zenodo.842223
optional order number

Preface

We hebben een 10m x 10m grid met landgebruik (9 klassen) op 4 tijdstippen tussen 1774 en 2022. Er is een validatie van de rasterbeelden gemaakt obv een random gegenereerde puntenlaag. Bovendien is voor die validatiepunten ook gekeken naar het landgebruik op tussenliggende kaarten, waarop het landgebruik niet gedetecteerd is. De combinatie van 9 klassen op 4 (of meer) tijdstippen geeft zeer veel info. Het lijkt ons aangewezen om een procedure te ontwikkelen om zoveel mogelijk info te behouden maar toch de fout (detectiefout + LU change tussen de tijdstippen) te beperken. Dus wellicht door klassen te clusteren tot op het optimale niveau.

1 DE DATA

Gedurende de analyses zal er gebruik gemaakt worden van twee datasets:

- Een **dataset** met de geobserveerde waarde en referentiewaarde.

Deze dataset bevat 1824 observaties en 13 variabelen. De observaties vertegenwoordigen punten die gestratificeerd zijn getrokken uit een puntenwolk. Voor elk van de 30 verschillende strata, waarbij een stratum een type landgebruik representeert, werden punten getrokken. De punten werden binnen elk stratum getrokken op volgorde van toenemende ID. In totaal werden er 2448 punten geselecteerd uit de puntenwolk en op de kaart van 1969 als uitgangspunt. Alle punten in de overlay met een landgebruik dat tussen 1778 en 1969 niet veranderde, zijn gevalideerd. Voor de punten die behoren tot klassen met landgebruik dat tussen 1778 en 1969 wel veranderde en waarvan minimaal 10 punten in de overlay voorkomen, werd 30% gevalideerd (dus minimaal 3 punten). De belangrijkste variabelen zijn LU_1969_1873_1774_true en LU_2022_1969_1873_1774_pred, welke respectievelijk de referentiewaarde en de geobserveerde waarde aangeven.

- Een **dataset** met alle mogelijke veranderingen in landgebruik (LU) zijn er in totaal 9^4 (10^4) combinaties, aangezien er 9 verschillende landgebruikstypes en 4 verschillende tijdstippen zijn. De dataset bevat echter slechts 6749 van deze mogelijkheden. Voor elke combinatie worden de totale oppervlakte (in m^2 en ha) en de cumulatieve oppervlakte (in ha en %) weergegeven.

Tabel 1.1: De gebruikte landgebruikstypes

LU nummer	LU naam
9	water
8	boomgaard
7	moeras
6	strand, slikke en schorre
5	heide en duinen
4	grasland
3	bos
2	bebouwing, tuin, infrastructuur
1	akker

1.1 INITIËLE DATA VERKENNING

De volgende controles werden uitgevoerd om de consistentie van de gegevens te waarborgen:

- Of de referentie identiek is aan de afzonderlijke referentiejaren

De referentie was identiek aan de afzonderlijke referentiejaren.

- Of de lengte van de referentie precies 3 is

Er werden 2 observaties gevonden met een waarde verschillend van 3 (fid zijn 806 en 1393).

- Of de lengte van de observatie precies 4 is

2 CLUSTERING

Er werden in totaal 6 verschillende functies geschreven om de observaties te clusteren:

2.1 MASK FOLLOW UP

Doel

De functie `mask_follow_up` clustert een reeks landgebruikscodes (LU-codes) op basis van een opgegeven clusteringpositie. Dit betekent dat alle opeenvolgende karakters na de clusteringpositie worden gecontroleerd en vervangen door "X" zodra een verschil wordt gedetecteerd.

Parameters

- **variable** (character vector): Een vector met landgebruikscodes, elk bestaande uit een reeks karakters.
- **clustering_position** (integer): De index van het karakter waarop clustering wordt gebaseerd. Dit is de startpositie van de clustering.

Voorbeeld

Input:

```
mask_follow_up(c("11123", "22345", "33333"), clustering_position = 2)
```

output:

```
[1] "111XX" "22XXX" "33333"
```

2.2 MASK FOLLOW UP INTENSITY

Doel

De functie `mask_follow_up_intensity` bouwt verder op `mask_follow_up`, maar voegt extra logica toe om de intensiteit van het landgebruik te bepalen. Dit wordt gedaan door te kijken of het landgebruik als intensief of extensief wordt geclassificeerd.

Parameters

- variable (character vector): Een vector met landgebruikscodes.
- LU-classes (akker, bebouwing, ..., water) (integers, standaardwaarden 1 t/m 9): Codering voor verschillende typen landgebruik.
- clustering_position (integer): De startpositie van de clustering.

Voorbeeld

Input:

```
mask_follow_up_intensity(c("11123", "22345", "33333"), clustering_position = 2)
```

output:

```
[1] "111XX_I" "22XXX_E" "33333_E"
```

2.3 MAKE_BIN_CHANGE

Doel

De functie `make_bin_change` vergelijkt de LU-code op twee specifieke posities en bepaalt of er een verandering in landgebruik heeft plaatsgevonden.

Parameters

- `variable` (character vector): Een vector met landgebruikscodes.
- `clustering_position` (integer): De index van het karakter dat als startpunt wordt gebruikt.
- `reference_position` (integer): De index van het karakter dat als referentie wordt gebruikt.

Voorbeeld

Input:

```
make_bin_change(c("12345", "22345", "33445"), clustering_position = 1, reference_position = 3)
```

Output:

```
[1] "Changed" "Changed" "Changed"
```

Hier wordt gekeken of het 1e karakter (clustering) en het 3e karakter (referentie) gelijk zijn.

2.4 CHANGE_FREQUENCY

Doel

Deze functie analyseert hoe vaak en op welke manier landgebruik (LU) is veranderd tussen twee tijdstippen: een referentiejaar en een clusteringjaar. Het classificeert de verandering in verschillende categorieën, zoals stabiel, verschoven of volledig dynamisch.

Parameters

- `variable` (character vector): Een vector met LU-codes over de tijd.
- `reference_position` (integer): De index van de LU-code in het referentiejaar.
- `clustering_position` (integer): De index van de LU-code in het clusteringjaar.

Uitvoer

De functie geeft een tekstuele classificatie terug, zoals:

- "Stable (No Change)" = Geen verandering.
- "Reverted (1 LU in between)" = Eén tussenliggende LU die uiteindelijk terugkeert naar het originele LU.
- "Shifted (1 Change)" = Eén verandering zonder terugkeer naar het originele LU.
- "Reverted (2 LUs in between)" = Twee tussenliggende LU's die terugkeren naar het originele LU.
- "Shifted (2 LU Changes)" = Twee LU-wijzigingen zonder terugkeer.
- "Fully Dynamic (All Different)" = Elk LU in de reeks is uniek.
- "Multiple changes" = Andere patronen van verandering.

Input:

```
change_frequency(c("12345", "22345", "33445"), clustering_position = 1,  
reference_position = 3)
```

Output:

```
           12345           22345           33445  
"Shifted (2 LU Changes)"  "Shifted (1 Change)"  "Shifted (1 Change)"
```

//

Doel

Deze functie bepaalt of een bepaalde landgebruiksklasse (LU) aanwezig, afwezig, verworven of verloren is in een bepaalde periode.

Parameters

- `variable` (character vector): Een vector met LU-codes.
- `clustering_position` (integer): De startpositie voor de analyse.
- `reference_position` (integer): De eindpositie voor de analyse.
- `LU` (character): De specifieke LU-code waarvoor de aanwezigheid wordt gecontroleerd.

Uitvoer

De functie retourneert een van de volgende categorieën:

- “Stable presence” → De LU is gedurende de hele periode aanwezig.
- “Stable absence” → De LU is nooit aanwezig.
- “Stable loss” → De LU verdwijnt vroeg in de periode en komt niet terug.
- “Eventual loss” → De LU verdwijnt later in de periode.
- “Eventual gain” → De LU verschijnt later in de periode.
- “Stable gain” → De LU is aanwezig vanaf het begin en blijft bestaan.
- “Intermittent Presence” → De LU is soms aanwezig en soms niet.

Input:

```
presence(c("12345", "22345", "33445"), clustering_position = 1,  
         reference_position = 3, LU = 4)
```

Output:

12345	22345	33445
"Stable absence"	"Stable absence"	"Stable loss"

TRANSITION PRESENT

Doel

Deze functie controleert of een bepaalde overgang (transitie) van LU's voorkomt in een bepaalde periode en classificeert hoe deze transitie zich gedraagt.

Parameters

- **variable** (character vector): Een vector met LU-sequenties over de tijd.
- **transition** (character): De overgang van LU's die wordt gezocht (bijv. "12" voor een overgang van LU 1 naar LU 2).
- **clustering_position** (integer): De beginpositie van de analyse.
- **reference_position** (integer): De eindpositie van de analyse.

Uitvoer

De functie retourneert een tekstuele beschrijving van hoe vaak en in welke vorm de transitie voorkomt, zoals:

- “Transitie 1 keer aanwezig en laatste LU van de transitie duikt niet opnieuw op” → De transitie gebeurt één keer en de laatste LU van de overgang komt niet meer terug.

- Input:

```
transition_present(c("12345", "22345", "33445"), clustering_position = 1,
                  reference_position = 3, transition = 23)
```

Input:


Output:

	observed	reference	prediction_change_frequency	reference_change_frequency
1	1122	1111	Shifted (1 Change)	Stable (No Change)
2	2233	2222	Shifted (1 Change)	Stable (No Change)
3	3344	3333	Shifted (1 Change)	Stable (No Change)
4	4455	4444	Shifted (1 Change)	Stable (No Change)

This is a watermark

Tabel 2.1: De totale accuraatheid is {{round(OA, 3)}} met een variantie van.

	Class: Fully Dynamic (All Different)	Class: Reverted (1 LU in between)	Class: Reverted (2 LUs in between)	Class: Shifted (1 Change)	Class: Shifted (2 LU Changes)	Class: Stable (No Change)
Sensitivity	0.73	0.64	0.44	0.85	0.74	0.85
Specificity	0.99	0.97	1.00	0.88	0.93	0.97
Pos Pred Value	0.55	0.66	0.54	0.82	0.70	0.93
Neg Pred Value	0.99	0.97	1.00	0.90	0.94	0.93
Precision	0.55	0.66	0.54	0.82	0.70	0.93
Recall	0.73	0.64	0.44	0.85	0.74	0.85
F1	0.63	0.65	0.48	0.84	0.72	0.89
Prevalence	0.02	0.07	0.01	0.39	0.18	0.33
Detection Rate	0.01	0.05	0.00	0.33	0.13	0.28
Detection Preva- lence	0.03	0.07	0.01	0.41	0.19	0.30
Balanced Accuracy	0.86	0.81	0.72	0.87	0.84	0.91



Figuur 2.1: Plot of the PA and U after clustering.

De functie `clustering_area` is een vereenvoudigde versie van clustering functie, die het mogelijk maakt om clustering toe te passen op één dataset zonder een externe referentie. Dit betekent dat de clustering puur wordt toegepast op de opgegeven data (variable) zonder externe vergelijkingen. Dit is handig voor de dataset met alle mogelijke veranderingen in landgebruik (LU).

Deze dataset bevat getallen kleiner dan 1000. Wil dit zeggen dat in deze gevallen er 0 moet voorkomen om aan 4 cijfers te geraken? In dit geval zou "10" "0010" worden.

vlaanderen.be/inbo

Tabel 3.1: User and producer accuracy based on own formules based on Olofsson et al.. De overall accuracy is $\{\{\text{round}(\text{est}, 3)\}\}$ met een variantie van $\{\{\text{round}(\text{var}, 2)\}\}$.

class	ua_est	ua_var	ua_low	ua_high	pa_est	pa_var	pa_low	pa_high
Fully Dynamic (All Different)	0.551	0.005	0.410	0.692	0.774	0.004	0.657	0.891
Reverted (1 LU in between)	0.664	0.002	0.582	0.746	0.727	0.001	0.664	0.791
Reverted (2 LUs in between)	0.538	0.021	0.256	0.821	0.528	0.011	0.320	0.736
Shifted (1 Change)	0.820	0.000	0.792	0.848	0.809	0.000	0.781	0.837
Shifted (2 LU Changes)	0.699	0.001	0.650	0.748	0.780	0.000	0.745	0.815
Stable (No Change)	0.927	0.000	0.905	0.949	0.760	0.000	0.723	0.796

MAPAC

De gebruikt formules in dit package maken ook gebruik van de formules gedefinieerd door Olofsson et al.

Er werden geen significante verschillen gedetecteerd tussen de aa_card functie en de handgeschreven functies.

Tabel 3.2: User and producer accuracy based on own formules based on the MAPAC package. De overall accuracy is $\{\text{round}(\text{est}, 3)\}$ met een variantie van $\{\text{round}(\text{var}, 3)\}$.

class	ua	pa	p_i	p_i_se	ua_se	pa_se	w
Fully Dynamic (All Different)	0.551	0.774	0.032	0.004	0.071	0.060	0.044
Reverted (1 LU in between)	0.664	0.727	0.094	0.006	0.042	0.032	0.103
Reverted (2 LUs in between)	0.538	0.528	0.015	0.003	0.138	0.104	0.014
Shifted (1 Change)	0.820	0.809	0.385	0.009	0.014	0.014	0.380
Shifted (2 LU Changes)	0.699	0.780	0.234	0.008	0.025	0.018	0.261
Stable (No Change)	0.927	0.760	0.241	0.006	0.011	0.018	0.198

3.3 REGENESEES

ReGenesees (R Evolved Generalized Software for Sampling Estimates and Errors in Surveys) is een R-pakket voor het uitvoeren van design-based en model-assisted analyses van complexe steekproeven. Het ondersteunt multistage, gestratificeerde, geclusterde en ongelijk gewogen steekproefontwerpen. Voor niet-lineaire (gladde) schatters wordt de steekproefvariantie geschat met behulp van Taylor-reeks linearisatie.

De volgende stappen werden uitgevoerd:

- Elke predictie werd gekoppeld aan de totale oppervlakte er beschikbaar is van dat clustering niveau en de frequentie van de voorkomende clustering niveaus.
- de Inverse Probability Sampling (IPS) werd bepaald per clustering niveau door zijn frequentie te delen door zijn oppervlakte. De inverse hiervan wordt beschouwd als een gewicht voor de sampling units.
- Aan elke observatie werd een bepaalde naam gegeven (ids)

```
[1] 7046298
```

```
[1] 0
```

```
[1] -5707278
```

```
# Data frame of known totals for a *global* calibration task
```

```
- Number of rows:      1
```

```
- Number of columns:    6
```

```
- Number of known totals: 6
```

```
# The data frame structure is as follows
```

```
## Columns 1-6 identify known totals organized into *1 BLOCK*
```

```
- BLOCK 1 -----
- Benchmark:      Counts of map
- Known totals:   6
- Auxiliary variables: 6
- Columns:        1-6
```

```
      1              2
aux "Fully Dynamic (All Different)" "Reverted (1 LU in between)"
      3              4              5
aux "Reverted (2 LUs in between)" "Shifted (1 Change)" "Shifted (2 LU Changes)"
      6
aux "Stable (No Change)"
```

```
# Checking Known Totals dataframe: OK
```

```
Calibrated, Stratified 1 - Stage Cluster Sampling Design
```

```
- [6] strata
```

```
- [1822] clusters
```

```
Call:
```

```
ReGenesees::e.calibrate(design = design, df.population = df.pop,
  calmodel = ~map - 1)
```

```
Weights:
```

```
Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
```

```
////////////////////////////////////////////////////////////////////////////////////////////////////////////////////////////////
```

121.1 136.7 136.7 152.2 170.2 403.7

Sample stratum sizes:

	Fully Dynamic (All Different)	Reverted (1 LU in between)	
Obs	147	640	
PSUs	49	128	
	Reverted (2 LUs in between)	Shifted (1 Change)	Shifted (2 LU Changes)
Obs	52	3720	2052
PSUs	13	744	342
	Stable (No Change)		
Obs	2184		
PSUs	546		

Population stratum sizes:

	Stable (No Change)	Shifted (1 Change)	Reverted (1 LU in between)
PSUs	264469.5	508538.9	138127.1
	Shifted (2 LU Changes)	Fully Dynamic (All Different)	
PSUs	349213.5	59339.7	
	Reverted (2 LUs in between)		
PSUs	19331.8		

Data variables:

[1]	"map"	"ref"	"area_m2.x"	"area_ha"	"area_m2.y"
[6]	"n"	"ips"	"weights"	"ids"	"ones"
[11]	"oa"	"n_ref"	"prop_area_ha"	"weights.cal"	

g.min	g.max
0.1666667	0.3333333

All Calibration Constraints (6) fulfilled (at tolerance level epsilon = 1e-07).

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
121.1	136.7	136.7	152.2	170.2	403.7

	Total	SE
ones	1339020	1.673213e-09

v No differences

`old`: 10231.8 15214.0 8133.5 22497.0 21597.9 16417.0
`new`: 10227.2 15205.8 8130.1 22483.6 21586.4 16406.8



v No differences

`old`: 0.010423
`new`: 0.010417

v No differences


`old`: 0.071 0.042 0.138 0.014 0.025 0.011
`new`: 0.072 0.042 0.144 0.014 0.025 0.011

Histogram of aa\$stats\$ua_se – cal_ua\$SE.Mean.aa



v No differences

v No differences



Figuur 3.1: UA and PA based on the Regeneesees package.